### 1 Uwarunkowanie

$$\begin{array}{ll} \delta+1=\frac{1}{1-\delta} & \delta^2\approx 0 \\ \text{Błąd względny wyniku:} \end{array}$$

$$\left| \frac{f(\widetilde{x}) - f(x)}{f(x)} \right| = \left| \frac{xf'(x)}{f(x)} \right| |\delta|$$

$$cond(x) = \left| \frac{xf'(x)}{f(x)} \right| \qquad \sum_{k=1}^{n} \left| \frac{x_k \frac{\partial f}{\partial x_k}(x_1, \dots, x_k)}{f(x_1, \dots, x_k)} \right| \quad (f : \mathbb{R}^k \to \mathbb{R})$$

Uwarunkowanie zadania numerycznego

$$\frac{||f(\widetilde{d}) - f(d)||}{||f(d)||} \leq cond(d) \frac{||d - \widetilde{d}||}{||d||}$$

### 2 Normy

## 2.1 Wektorowe

$$||x||_2 = \sqrt{\sum_{i=1}^n x_i^2} \quad ||x||_1 = \sum_{i=1}^n |x_i|$$
  
$$||x||_{\infty} = \max_{i \in \{1, \dots, n\}} |x_k| \quad ||x||_p = \left(\sum_{i=1}^n |x_i|^p\right)^{\frac{1}{p}}$$

#### 2.2 Macierzowe

$$\begin{split} ||A||_1 &= \max_{j=1,...,n} \sum_{i=1}^n |a_{ij}| \quad ||A||_{\infty} = \max_{i=1,...,n} \sum_{j=1}^n |a_{ij}| \\ ||A||_2 &= \sup_{x \neq 0, \ x \in \mathbb{C}^n} \frac{||Ax||_2}{||x||_2} = \sqrt{\rho \left(A^*A\right)} \quad A^* = \overline{A}^T \\ ||A||_F &= \sqrt{\sum_{i=0}^n \sum_{j=0}^n |a_{ij}|^2} \end{split}$$

zgodność norm jeśli:  $||Ax|| \le ||A|| \cdot ||x||$  dla normy Frobeniusa:  $||Ax||_F \le ||A||_F ||x||_2$  dla dowolnej zachodzi:  $||AB|| \le ||A|| \cdot ||B||$ 

### 3 Arytmetyka zmienno przecinkowa (fl)

Zbiór M(2,t,k) nie jest zamknięty ze względu na działania arytmetyczne.  $fl(x\diamond y)=rd(x\diamond y)$  zatem błąd arytmetyki jest taki sam jak błąd arytmetyki reprezentacji wyniku. Zatem  $fl(x\diamond y)=(x\diamond y)(1+\delta)$  jeżeli  $x=m_1\cdot 2^{c_1}$   $y=m_2\cdot 2^{c_2}$  oraz  $c_1-c_2>t$  to fl(x+y)=x

### 4 Numeryczna poprawność

Def. Algorytm A dla zadania  $\varphi$  nazywamy numerycznie poprawnym jeśli istnieje stała k niezależna od wskaźnika uwarunkowania i niezależna od arytmetyki tż dla dowolnej danej  $d \in D$  istnieje dana  $\widetilde{d}$  tż  $||d-\widetilde{d}|| \leq K \cdot 2^{-t}||d||$  oraz  $fl(A(d)) = \varphi(\widetilde{d})$  Czyli, wynik algorytmu A dla danej d (dokładniej) w arytmetyce fl jest dokładnym wynikiem zadania  $\varphi$  dla nieco zaburzonej danej. Oszacowanie błędu alg. num. poprawnego:  $||fl(A(d)) - \varphi(d)|| \leq cond(d) \frac{K \cdot 2^{-t}||d||}{||d||} ||\varphi(d)||$ 

# 5 Interpolacja

# 5.1 Lagrange

 $p_n(x) = \sum_{i=0}^n f_i l_i(x)$ 

gdzie:

$$l_i(x) = \prod_{j=0, j \neq i}^{n} \frac{x - x_j}{x_i - x_j}$$

#### 5.2 Newton

$$c_0 + c_1(x - x_0) + c_2(x - x_0)(x - x_1) + \ldots + c_n(x - x_0) \ldots (x - x_{n-1})$$
gdzie:

$$c_k = f_{0,1,2,...,k}$$

oraz

$$f_{i,i+1,\dots,k+i} \stackrel{def}{=} \frac{f_{i+1,\dots,k} - f_{i,\dots,(i+k-1)}}{r_{i+k} - r_{i}}$$

Hermite identycznie tylko że w tabeli węzły się powtarzają i w miejscu różnic dzielonych których nie można otrzymać wpisujemy  $\frac{f^{(k)}(x_i)}{k!}$ a w wielomianie interpolacyjnym składniki postaci  $(x-x_i)$ będą posiadały odpowiednią potęgę

### 6 Całkowanie numeryczne

Kwadratura jest rzędu r jeśli jest dokładna dla wszystkich wielomian<br/>ów stopnie r-1 oraz istnieje wielomian stopnia r<br/> dla której nie jest dokładna

**6.1** Trapezy  $\xi \in (a,b)$  E(f) = I(f) - S(f)

$$S(f) = \sum_{k=1}^{N} \frac{x_k - x_{k-1}}{2} (f(x_k) + f(x_{k-1})) =$$

$$= \frac{H}{2} \left( f(a) + f(b) + 2 \sum_{k=1}^{N-1} f(a + kH) \right)$$

$$E(f) = -\sum_{k=1}^{N} \frac{H^3 f''(\xi_k)}{12} = -\frac{(b-a)^3}{12N^2} f''(\xi)$$

**6.2** Prostokąty  $\xi \in (a,b)$  E(f) = I(f) - S(f)

$$S(f) = \sum_{k=1}^{N} (x_k - x_{k-1}) f\left(\frac{x_k + x_{k-1}}{2}\right) = H \sum_{k=0}^{n} f\left(\frac{x_k + x_{k-1}}{2}\right)$$
$$E(f) = \frac{(b-a)^3}{24N^2} f''(\xi) = \frac{H^2}{24} (b-a) f''(\xi)$$

**6.3** Simpson  $\xi \in (a,b)$  E(f) = I(f) - S(f)

$$S(f) = \sum_{k=1}^{N} \frac{H}{6} \left( f(x_{k-1}) + 4f\left(x_{k-1} + \frac{H}{2}\right) + f(x_k) \right)$$
$$E(f) = -\sum_{k=1}^{N} \frac{H^5 f^{(4)}(\xi_k)}{90 \cdot 2^5} = -\frac{(b-a)^5}{2880N^4} f^{(4)}(\xi)$$

## 7 Rozwiązywanie układów r. liniowych $det A \neq 0$

#### 7.1 Metoda Eliminacji Gaussa GE

Tw.1 Jeśli A jest macierzą dodatnio określoną, to metoda GE zastosowana do Ax=b jest wykonalna Tw.2 Jeśli A jest silnie diagonalnie dominująca, to metoda GE zastosowana do układu Ax=b jest wykonalna

#### **7.2** GEPP

W k-tym kroku wybieramy wierszowo (analog. kolumnowo) max  $a_{i\in\{k,\dots,n\}}|a_{ik}|$  i zamieniamy k-ty wiersz z wierszem z maksymalnym el. w macierzy  $[A^{(k-1)}|b^{(k-1)}]$ 

### 7.3 **GECP**

w k-tym kroku znajdujemy p,q tż.  $|a_{pq}|=\max_{i,j\in\{1,\ldots,n\}}|a_{ij}|$  i zamieniamy p wiersz z k oraz q kolumnę z k przy zamianie kolumn następuje zamiana zmiennych w x

#### 7.4 Rozkład LU

 $Ax = b \Rightarrow LUx = b \Rightarrow Ly = b \land Ux = y$  (wyznaczamy y potem x)

#### 7.5 Rozkład PA=LU

 $Ax=b\Rightarrow PAx=Pb\Rightarrow LUx=Pb$  (i dalej tak samo jak w LU)

### 7.6 Banachiewicz-Cholesky

Jeśli  $A \in \mathbb{R}^{k \times k}$  jest symetryczna i dodatnio określona, to istnieje dokładnie jedna macierz L (dolnotrójkątna) z dodatnimi elementami na głównej przekątnej tż  $A = LL^T$  Fakt:  $\sqrt{\omega_1} = l_{11} \dots \sqrt{\frac{\omega_k}{\omega_{k-1}}} = l_{kk}$   $\omega$  wyznaczniki wiodących minorów głównych

Tw. Sylvestera dla każdego  $i \in [k]$   $\omega_i > 0 \Leftrightarrow A$  jest dodatnio określona

## 8 Iteracyjne metody rozwiązywania u.r.l.

Tw. Metoda iteracyjna  $x^{(k+1)}=Bx^k+c$  jest zbieżna globalnie  $\Leftrightarrow \rho(B)<1$  im  $\rho(B)$  mniejsze tym szybciej Tw. Jeśli ||B||<1 gdzie  $||\cdot||$  jest normą zgodną z pewną normą wektorową to metoda  $x^{(k+1)}=Bx^k+c$  jest zbieżna globalnie Tw. Greszgorin niech  $A\in\mathbb{C}^{n\times n}$ . Dla każdej wartości własnej  $\lambda\in\sigma(A)$  istnieje  $i\in\{1,\dots,n\}$  taki, że

$$\lambda \in K_i = \{ z \in \mathbb{C} : |z - a_{ii}| \le \sum_{j=1, j \ne i}^n |a_{ij}|$$

gdzie  $K_i$  to *i*-te koło Greszgorina. Ponadto  $\sigma(A) \subset \bigcup_{i=1}^n K_i = G(A)$  gdzie G(A) nazywany jest zbiorem Greszgorina.  $(A = A^T \to \lambda \in \mathbb{R})$  Warunki stopu:

1)  $||x^{(k+1)} - x^{(k)}|| \leq d$ błąd bezwzględny

2)  $||x^{(k+1)}-x^{(k)}|| \leq d||x^{(k)}||$ błąd względny

3)  $||x^{(k+1)} - x^{(k)}|| \le d_1 ||x^{(k)}|| + d_2$  warunek Gilla

4)  $||Ax^{(k)} - b|| \le d$  błąd residualny.

#### 8.1 Metoda Jacobiego

$$x^{(k+1)} = -D^{-1}(L+U)x^{(k)} + D^{-1}b$$
  
$$B = -D^{-1}(L+U)$$

W metodzie Jacobiego warunek dostateczny zbieżności  $||B||_{\infty} < 1$  jest spełniony np. wtedy, gdy macierz A jest silnie diagonalnie dominująca

$$\left(\sum_{j=1,i\neq j}^{n} |a_{ij}| \le |a_{ii}|\right)$$

for 
$$p=1,\ldots,n$$
 do  $x_p^{(k+1)}=\left(b_p-\sum_{j=1}^{p-1}a_{pj}x_j^{(k)}-\sum_{j=p+1}^na_{pj}x_j^{(k)}\right)/a_{pp}$  and for

#### 8.2 Gauss-Seidel

$$x^{(k+1)} = -(L+D)^{-1}Ux^{(k)} + (L+D)^{-1}Ux^{(k)} + (L+D)^{-1}Ux^{($$

 $x^{(k+1)}=-(L+D)^{-1}Ux^{(k)}+(L+D)^{-1}b$  Jeśli $A=A^T$ oraz Ajest dodatnio określona, to metoda Gaussa-Seidla jest zbieżna.

Jeśli A jest silnie diagonalnie dominująca to metoda Gaussa-Seidela jest zbieżna.

#### 8.3 Metoda SOR

$$\begin{split} B_{SOR} &= (D+\omega L)^{-1}((1-\omega)D-\omega U)\\ c_{SOR} &= \omega(D+\omega L)^{-1}b\\ x^{(k+1)} &= B_{SOR}x^{(k)} + c_{SOR} \end{split}$$

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}} \left( b_i - \sum_{i < i} a_{ij} x_j^{k+1} - \sum_{i > i} a_{ij} x_j^{(k)} \right)$$

Tw. Kahana: Dla metody SOR  $\rho(B_{SOR}) \geq |\omega-1|$  Tw. Jeśli A jest symetryczna i dodatnio określona, to metoda SOR jest zbieżna dla każdego  $\omega \in (0,2)$ 

### 8.4 Warunek zbieżności

$$\begin{array}{l} x = Bx + c \\ x - x^{(k+1)} = Bx + c - x^{(k+1)} = Bx + c - Bx^{(k)} - c \\ x - x^{(k+1)} = B(x - x^{(k)}) = \ldots = B^{k+1}(x - x^{(0)}) \\ \lim_{k \to \inf} e_k = 0 \Leftrightarrow \lim_{k \to \inf} B^{k+1} = 0 \end{array}$$

### Wyznaczanie m. zerowych funkcji 1 zmiennej

## Metoda Newtona

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

Jeżeli 1) f jest klasy  $C^2([a,b])$  2) f(a)f(b) < 0 3) f' i f'' nie zmieniają znaku na [a,b] 4)  $x_0$  jest takie, że  $f(x_0)f''>0$  to metoda

Błąd k-tego przybliżenia można oszacować nierówności z subsekcji  $\bf 9.6$ Metoda Newtona jest metodą o zbieżności kwadratowej (rząd zbieżności wynosi 2). Wyjątkiem są zera wielokrotne, dla których zbieżność jest liniowa i wynosi 1. Jej współczynnik zbieżności to  $\frac{M}{2m}$ Oznacza to, iż przy spełnionych założeniach błąd maleje kwadratowo wraz z ilością iteracji.

### 9.2 Metoda siecznych

$$\begin{split} x_{k+1} &= x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} \\ \text{Warunki zb. te same tylko oba } x_0 \text{ i } x_1 \text{ muszą spełniać 4}) \end{split}$$

## 9.3 Metoda Halley'a

$$x_{k+1} = x_k - \frac{f(k_k)}{f'(k_k) - \frac{f(x_k)}{2f'(k_k)}f''(k_k)}$$

### 9.4 Metoda Parabol

$$p_k=x_{k+1}-x_k$$
rozwiązujemy  $f(x_k)+f'(x_k)p_k+\frac{1}{2}f''(x_k)p_k^2=0$  (deltą) jako  $p_k=\min\{|p_k^{(1)}|,|p_k^{(2)}|\}$  obliczamy  $x_{k+1}=p_k+x_k$ 

#### 9.5 Metoda Bisekcji

$$\begin{array}{l} f \ \mathrm{ciagla} \ [a,b] \ \mathrm{t}\dot{z} \ f(a)f(b) < 0 \\ \mathbf{for} \ p = 1, \dots, \ \mathbf{do} \\ t_k = \frac{a_k + b_k}{2} \\ \mathbf{if} \ f(a_k)f(t_k) < 0 \ \mathbf{then} \\ a_{k+1} = a_k \ b_{k+1} = t_k \\ \mathbf{else} \ \mathbf{if} \ f(a_k)f(t_k) > 0 \ \mathbf{then} \\ a_{k+1} = t_k \ b_{k+1} = b_k \end{array}$$

 $_{
m else}$ wynik  $t_k$ end if end for

#### 9.6 Zbieżność

Przyjmijmy, że  $e_k = x_k - \alpha$ jest błędem w k-tymkroku Jeśli istnieją liczby pi ctż  $\lim_{k\to\inf}\frac{|e_{k+1}|}{|e_k|^p}=c$ to pnazywamy wykładnikiem zbieżności metody iteracyjnej

 $|e_{k+1}| \leq c |e_k|^p$ im p<br/> większe tym metoda szybsza

Newtona p=2, Stycznych  $p=\frac{1+\sqrt{5}}{2}$ , Halleg'a p=3, Parabol p=3, Bisekcji  $p=1\,$ 

Dla Newtona (dd z Taylora w ot.  $x_0$ ) dla miejsc pojedynczych

$$|e_{k+1}| \le \frac{1}{2} \left| \frac{f''(\xi)}{f'(x_k)} \right| |e_k|^2$$

## Rozwiązywanie układów równań nielinowych

TO DO:

- 10.1Metoda Richardsona
- Metoda Parabol 10.2
- Metoda iteracji prostej 10.3
- Uwarunkowanie zadania roz. u.r.l

$$\begin{split} cond(A) &= ||A|| \ ||A^{-1}|| \\ cond_2(A) &= ||A||_2 \ ||A^{-1}||_2 = \frac{\lambda_{max}(A)}{\lambda_{min}(A)} \\ &\quad \text{Jeśli} \ A = A^T, \ \text{to} \\ ||A||_2 &= \sqrt{\rho(A^TA)} = \sqrt{\rho(A^2)} = \sqrt{(\rho(A))^2} = \rho(A) \\ ||A^{-1}||_2 &= \left|\frac{1}{\lambda_{min}(A)}\right| \end{split}$$